

Estadística Descriptiva e Inferencial Aplicada

Sesión 1: Gestión y Preparación de Datos Económicos

Escuela Global

2026-09-07

Sección 1

Introducción

Escenario Profesional Típico

Una organización recibe una base de datos que contiene: - Registros de transacciones (miles de filas) - Información de múltiples fuentes: finanzas, operaciones, recursos humanos - Datos de diversos sectores económicos (Finanzas, Retail, Manufactura, Educación, Logística) - Problemas de calidad variados e inconsistencias documentadas

Pregunta Central: ¿Cómo convertir datos crudos y problemáticos en información confiable?

Distribución del Esfuerzo en Proyectos Reales

- **80 %** del tiempo: Importación, diagnóstico, limpieza y transformación de datos
- **15 %** del tiempo: Análisis estadístico y modelado
- **5 %** del tiempo: Visualización e interpretación de resultados

Los mejores analistas profesionales dedican la mayor parte del tiempo a garantizar calidad de datos.

Objetivos de Aprendizaje

Al término de esta sesión, el participante será capaz de:

Competencias Desarrolladas

- 1 Importar datos desde múltiples formatos a Excel
- 2 Diagnosticar problemas de calidad usando herramientas de Excel
- 3 Limpiar inconsistencias de forma sistemática
- 4 Transformar variables (fechas, texto, numéricas)
- 5 Crear variables derivadas con significado económico
- 6 Documentar completamente el proceso de preparación
- 7 **Migrar de forma natural a R para automatizar**

Sección 2

Teoría Fundamental

Tipos de Datos y Variables Económicas

Variables Numéricas - Continuas:

Precios (\$100.50), tasas (2.5 %) -

Discretas: Empleados (120),
transacciones (5)

Variables Categóricas - Nominales:

Sector (Finanzas, Retail) - Ordinales:

Tamaño (Pequeña, Mediana, Grande)

Variables Temporales - Fechas

específicas (2024-01-15) - Períodos
(trimestral, anual)

Variables de Texto - Descripciones,

notas, comentarios - Requieren

limpieza especial

Clasificación por Escala de Medición

Nominal - Sin orden, solo categorías - Ej: Finanzas, Retail

Ordinal - Con orden jerárquico - Ej: Baja, Media, Alta

Intervalo - Diferencias significativas - Ej: Temperatura, Índices

Ratio - Cero absoluto, ratios válidos - Ej: Precio, Volumen, Ingreso

Inconsistencias que Encontrarás

- 1 **Fechas:** Múltiples formatos (DD/MM/YYYY, YYYY-MM-DD, texto)
- 2 **Texto:** Espacios extras, mayúsculas inconsistentes
- 3 **Números:** Valores negativos sin justificación, símbolos de moneda
- 4 **Faltantes:** Celdas vacías sin patrón aparente ("NA", "-", " ")
- 5 **Duplicados:** Registros repetidos sin identificación clara ("Finanzas", "FINANZAS", "Finanzas")
- 6 **Rangos:** Valores fuera del rango esperado

Nacionales:

- 1 Institutos de Estadística: INEI (Perú)
- 2 Bancos Centrales: BCRP (Perú)
- 3 Entidades gubernamentales: Ministerios, Plataformas gubernamentales.
- 4 Insitutos de Estudios Económicos: Instituto Peruano de Economía (IPE)

Internacionales:

- 1 Banco Mundial (World Bank): Datos Socioeconómicos.
- 2 Fondo Monetario Internacional: Estadísticas Financieras Internacionales. Balanza de Pagos.
- 3 Yahoo Finance: Información de instrumentos financieros.
- 4 FRED (Federal Reserve Economic Data): Información económica gestionada por la Reserva Federal de Estados Unidos.

i ¿Los datos que 'importan' solo son Cuantitativos?

No. Todos los datos no son cuantificables al 100 %. Existe una gran cantidad de datos que son, por ejemplo, Cualitativos no normalizados. Ejemplo: Sentimientos, Opiniones, Razonamiento, Justificaciones.

¿Cuál sería la mayor fuente de datos cualitativos?

Sección 3

Gestión de Datos en Excel

Paso 1: Importar Datos a Excel

Opción A: Abrir archivo CSV

Instrucción paso a paso:

- 1 Abre Excel
- 2 Archivo → Abrir
- 3 Selecciona `datos_crudos.csv`
- 4 En el asistente de importación:
 - Delimitador: "Comma" (coma)
 - Encoding: UTF-8
 - Click Finish

Opción B: Copiar desde otra fuente

- 1 Copiar datos
- 2 Excel → Paste → Paste Special
- 3 Seleccionar formato (valores, fórmulas, etc.)

En archivo Excel: Ver hoja "Datos Importados"

Paso 2: Diagnóstico Visual en Excel

Instrucciones:

- ➊ Abre Ex_1_1.xlsx
- ➋ Ve a hoja "Datos Crudos" (encabezado ROJO)
- ➌ **Observa visualmente** los problemas:
 - Fila 2: Fecha formato diferente
 - Fila 3: Fecha como texto ("1 de enero")
 - Fila 4: Sector con espacios
 - Fila 2: Ingresos negativos (-30000)
 - Fila 3: Empleados vacío
 - Fila 4 y 7: Mayúsculas inconsistentes

Pregunta para reflexión: ¿Cuántos problemas identificas?

Ejercicio 1: Diagnóstico en Excel

Instrucción:

- ① Abre Ex_1_1.xlsx
- ② Hoja “Diagnóstico Manual”
- ③ Completa la tabla:
 - Problema detectado
 - Fila donde ocurre
 - Tipo (Fecha, Texto, Número, Faltante)
 - Severidad (Baja, Media, Alta)

Tiempo: 15 minutos

Preguntas: 1. ¿Cuántos problemas encontraste? 2. ¿Cuál es el más frecuente? 3. ¿Cuál afectaría más al análisis?

Problemas principales en Datos Crudos:

Tipo	Cantidad	Ejemplos
Fechas múltiples formatos	3	Filas 2, 3, 4
Espacios en texto	2	Filas 4, 7
Mayúsculas inconsistentes	4	Filas 2, 3, 4, 7
Ingresos negativos	1	Fila 2
Valores faltantes	1	Fila 3, columna Empleados

Total de inconsistencias: 11 problemas en 8 registros

Sección 4

Limpieza de Datos en Excel

Paso 3: Limpiar Nombres de Columnas

En Excel, esta es una tarea VISUAL:

- ① Ve a “Datos Crudos”
- ② Observa los nombres de columnas: ID, fecha, sector, ingresos, empleados
- ③ **Verifica que NO haya:**
 - Espacios extras
 - Caracteres especiales
 - Mayúsculas inconsistentes

En este caso: Los nombres ya están limpios

Paso 4: Limpiar Texto - TRIM y MAYUS

El problema: Espacios y mayúsculas inconsistentes

Solución en Excel:

Crea una columna auxiliar con la fórmula:

```
=MAYUS(TRIM(C2))
```

Donde: - TRIM(): Elimina espacios al inicio y final - MAYUS(): Convierte a mayúsculas

Instrucciones paso a paso:

- 1 Abre hoja "Paso_3_Limpiar_Texto" en Excel
- 2 Columna D (auxiliar): Inserta fórmula =MAYUS(TRIM(C2))
- 3 Copia hacia abajo hasta fila 9
- 4 Observa los resultados

Ejercicio 2: Limpiar Texto en Excel

Instrucción:

- 1 Abre Ex_1_1.xlsx
- 2 Hoja "Paso_3_Limpiar_Texto"
- 3 Columna D: Aplica =MAYUS(TRIM(C2))
- 4 Copia la fórmula hacia abajo
- 5 Columna E: Copia los resultados limpios
- 6 Compara columna C (sucio) vs E (limpio)

Tiempo: 10 minutos

Preguntas: 1. ¿La fórmula funcionó? 2. ¿Qué cambió en los datos? 3. ¿Faltó algo?

Resultado esperado en Columna E (limpia):

FINANZAS

FINANZAS

FINANZAS

FINANZAS

RETAIL

RETAIL

RETAIL

MANUFACTURA

Observación: Todos estandarizados a mayúsculas, sin espacios

En Excel: Copia estos valores y pega sobre la columna original (Paste Special → Values Only)

Paso 5: Convertir Fechas

El problema: Fechas en 3 formatos diferentes

01/01/2024 (DD/MM/YYYY)

2024-01-02 (YYYY-MM-DD)

1 de enero (Texto)

Solución en Excel:

- 1 Selecciona la columna de fechas
- 2 Data → Text to Columns
- 3 Delimitador: (ninguno)
- 4 Formato de datos: Date → YYYY-MM-DD
- 5 Click Finish

O manualmente:

```
=DATEVALUE(B2)
```

Ejercicio 3: Convertir Fechas en Excel

Instrucción :

- 1 Abre Ex_1_1.xlsx
- 2 Hoja "Paso_4_Convertir_Fechas"
- 3 Selecciona columna B (fechas)
- 4 Data → Text to Columns
- 5 Avanza hasta "Column Data Format"
- 6 Selecciona "Date" → Formato YYYY-MM-DD
- 7 Observa el resultado

Tiempo: 10 minutos

Preguntas: 1. ¿Todas las fechas se convirtieron? 2. ¿Hay alguna que no se convirtió? 3. ¿Por qué?

Fechas convertidas correctamente:

2024-01-01

2024-01-02

(ERROR) - No se puede convertir "1 de enero"

2024-04-01

...

Conclusión: "1 de enero" debe corregirse manualmente a 2024-01-01

En Excel: Selecciona esa celda y escribe manualmente la fecha

Paso 6: Detectar Valores Faltantes

En Excel, detectar NA es VISUAL:

- 1 Ve a la hoja “Datos Crudos”
- 2 Columna “empleados”
- 3 Fila 3: Vacía (NA)

Solución 1 - Usar fórmula CONTAR.BLANCOS:

```
=CONTAR.BLANCOS(E2:E9)
```

Resultado: 1 valor faltante

Solución 2 - Reemplazar:

- 1 Ctrl+H (Find & Replace)
- 2 Find: (dejar vacío)
- 3 Replace with: NA
- 4 Click Replace All

Ejercicio 4: Detectar y Marcar Faltantes en Excel

Instrucción :

- 1 Abre Ex_1_1.xlsx
- 2 Hoja "Datos Crudos"
- 3 Columna F (nueva): =IF(ISBLANK(E2),"FALTANTE","OK")
- 4 Copia hacia abajo
- 5 Observa qué filas tienen FALTANTE
- 6 En la hoja "Problemas", documenta qué hacer

Tiempo: 8 minutos

Decisión (para después): - ¿Eliminar la fila? - ¿Imputar con la mediana? - ¿Imputar con el promedio?

Paso 7: Manejar Valores Negativos

El problema: Ingresos negativos (-30000)

Preguntas a responder PRIMERO: 1. ¿Es un error de entrada? 2. ¿Es una devolución legítima? 3. ¿Es un ajuste contable?

En Excel - Solución 1: Marcar para revisión

```
=IF(D2<0,"REVISAR","OK")
```

En Excel - Solución 2: Convertir a positivos

```
=ABS(D2)
```

Ejercicio 5: Marcar Valores Negativos en Excel

Instrucción :

- 1 Abre Ex_1_1.xlsx
- 2 Hoja "Datos Crudos"
- 3 Columna G (nueva): =IF(D2<0,"NEGATIVO","OK")
- 4 Copia hacia abajo
- 5 Observa cuál fila tiene NEGATIVO
- 6 Decide: ¿revisar o convertir a positivo?

Para este ejemplo: Convertir a positivo

Columna H: =ABS(D2)

Tiempo: 8 minutos

Paso 8: Crear Variables Derivadas en Excel

Variables con significado económico:

`Ingresos por Empleado = Ingresos / Empleados`

En Excel:

- 1 Abre Ex_1_1.xlsx
- 2 Hoja "Datos Limpios" (encabezado VERDE)
- 3 Columna F: =E2/E2 (Ingresos / Empleados)
- 4 Copia hacia abajo
- 5 Resultado: Eficiencia por empleado

Ejercicio 6: Crear Variables Derivadas en Excel

Instrucción :

- 1 Abre Ex_1_1.xlsx
- 2 Hoja "Datos Limpios"
- 3 Columna F: Ingreso por Empleado
- 4 Fórmula: $=E2/F2$
- 5 Copia hacia abajo hasta fila 9
- 6 Observa los valores calculados

Preguntas: 1. ¿Cuál sector tiene mayor eficiencia? 2. ¿Cuál tiene menor? 3. ¿Tiene sentido el resultado?

Tiempo: 10 minutos

Paso 9: Documentar en Excel

Crear Diccionario de Variables:

① Nueva hoja: “Diccionario”

② Tabla:

Variable	Descripción	Tipo	Unidad	Rango
ID	Identificador único	Numérico	-	1-35
fecha	Fecha transacción	Fecha	YYYY-MM-DD	2024-01-01 a 2024-06-01
sector	Sector económico	Texto	-	Finanzas, Retail, Manufactura
ingresos	Ingresos netos	Numérico	USD	30000-70000
empleados	Cantidad de empleados	Numérico	Personas	90-150
ingresos	Ingresos netos	Numérico	USD / Persona	300-600

Ejercicio 7: Documentar en Excel

Instrucción :

- ① Abre Ex_1_1.xlsx
- ② Crea nueva hoja: “Diccionario”
- ③ Completa la tabla (ver ejemplo anterior)
- ④ Para cada variable:
 - Descripción clara
 - Tipo de dato
 - Unidad de medida
 - Rango de valores

Tiempo: 15 minutos

Importancia: Otros analistas entiendan tus datos

Ejercicio Aplicativo:

Eres analista en una firma de inversiones ubicada en Miami enfocada en economías emergentes. Te han encargado realizar un análisis rápido de las últimas cotizaciones de Credicorp Ltd. (Ticket: BAP) que han sido extraídas de Investing.com, preparándolos para un análisis financiero posterior.

Sección 5

Power Query en Excel

¿Qué es Power Query?

Definición

Power Query es el **motor de transformación de datos** integrado en Excel (pestaña Datos → Obtener y Transformar). Permite:

- Importar datos desde múltiples fuentes (CSV, bases de datos, APIs, web)
- Transformar y limpiar datos sin modificar el archivo original
- Automatizar procesos repetitivos de preparación
- Documentar cada paso de transformación de forma auditable

Ventaja clave: Todo lo que hicimos manualmente con fórmulas, Power Query lo hace en un pipeline visual y reproducible.

Power Query vs Fórmulas Manuales

Fórmulas Manuales

- =TRIM(C2) celda por celda
- Columnas auxiliares
- Difícil auditar
- Se rompe al cambiar datos
- No escala

Power Query

- Transformación en bloque
- Sin columnas auxiliares
- Cada paso documentado
- Se actualiza con Refresh
- Escala a millones de filas

Instrucciones paso a paso:

- 1 Excel → pestaña **Datos**
- 2 Sección **Obtener y Transformar Datos**
- 3 Click **Desde libro** (si ya tienes Excel)
- 4 O **Desde texto/CSV** (si importas)
- 5 Se abre el **Editor de Power Query**

El editor tiene 3 paneles:

- Izquierda: Consultas (queries)
- Centro: Vista previa de datos
- Derecha: **Pasos aplicados** (el pipeline)

¿Dónde se usa en la práctica?

- 1 **Comercio exterior:** Consolidar registros de importaciones/exportaciones mensuales
- 2 **Finanzas corporativas:** Unificar estados financieros de subsidiarias en distintas monedas
- 3 **Análisis de precios:** Transformar tablas anchas (meses en columnas) a formato largo para análisis
- 4 **Indicadores macro:** Extraer datos del Banco Mundial o FMI desde web y estructurarlos
- 5 **Consolidación multi-fuente:** Combinar CSVs, hojas Excel y bases de datos en una sola tabla

Ejercicio: Limpieza de Datos Educativos Globales (ONU)

Contexto

Trabajaremos con el dataset “**Datos Educativos Globales**” publicado en Kaggle, extraído del portal de datos de las Naciones Unidas (UN Data). Contiene indicadores educativos (tasas de matriculación, alfabetización, etc.) de múltiples países y años.

Supondremos que somos parte del equipo de especialistas de una organización enfocada en analizar la educación primaria en Colombia y Perú. Nos han solicitado obtener un cuadro comparativo con la información sobre la tasa de matrícula Primaria.

Toma el archivo “dataset_edu_ONU.xlsx” y presenta lo solicitado para presentar.

Estructura original (7 columnas):

Columna	Descripción
Índice	Número único por fila
ID	Identificador numérico
País	Nombre del país
Año	Año del registro
Tipo de Dato Educativo	Categoría (matriculación, alfabetización, etc.)
Tasa	Valor numérico del indicador
Fuente de Datos	Origen (ONU)

Datos Faltantes: ¿Por Qué Importan?

Un **dato faltante** (NA) es una observación que debería existir pero no fue registrada. En Excel aparece como celda vacía.

Consecuencias si no se tratan:

- =PROMEDIO() ignora vacíos silenciosamente → sesgo invisible
- Modelos eliminan filas completas → pérdida masiva de información
- Decisiones basadas en datos incompletos → riesgo financiero

En la práctica: Bases de comercio internacional tienen entre 3-8 % de campos vacíos. Un dataset de 1000 registros con 6 % de faltantes en una columna significa ~60 decisiones tomadas sin información.

Clasificación de Datos Faltantes (Rubin, 1976)

Tipo	Significado	Ejemplo Comercio Internacional
MCAR	Falta por puro azar	Servidor de aduanas se cae 2 horas
MAR	Falta por otra variable observable	Empresas pequeñas no reportan volumen
MNAR	Falta por el valor mismo	Empresas con aranceles altos los omiten

Regla práctica:

- $< 5\%$ y sin patrón $\rightarrow$ tratar como MCAR
- Faltantes correlacionan con un grupo $\rightarrow$ MAR, imputar por grupo
- Razón lógica para que el valor cause la ausencia $\rightarrow$ MNAR, documentar

Métodos de Tratamiento

Método	Cuándo Usarlo	En Excel
Eliminar filas	MCAR, $< 5\%$ faltantes	Filtrar → Eliminar
Eliminar columna	Variable con $> 50\%$ vacíos	Eliminar columna
Media/Mediana global	MCAR, solución rápida	=IF(ISBLANK(), MEDIAN())
Mediana por grupo	MAR (lo más recomendable)	Fórmula matricial
Interpolación	Solo series temporales	Promedio anterior/posterior
Regresión / KNN / MICE	MAR complejo, $> 20\%$	Requiere R o Python

Advertencia: Reemplazar con **cero** no es imputar. Cero es un valor; vacío es ausencia de información. Confundirlos distorsiona todo el análisis posterior.

Ejercicio: Limpieza de Datos de Comercio Internacional

Situación

La gerencia de operaciones recibe mensualmente el archivo `datos_comercio_internacional.csv` con 1020 registros de importaciones y exportaciones de 10 países y 8 sectores. El archivo presenta: duplicados, fechas en múltiples formatos, texto inconsistente (espacios, mayúsculas, códigos ISO), símbolos en campos numéricos (\$, %), valores negativos sin justificación, y **datos faltantes entre el 1 % y 6 %** en 9 de sus 11 columnas.

Objetivo: Usando exclusivamente **Power Query**, entregar una tabla limpia donde: no existan duplicados, todo el texto esté estandarizado, los campos numéricos sean números válidos, y los datos faltantes estén tratados con el método adecuado según su patrón. Documenta cada decisión en el panel de pasos aplicados.

Sección 6

Migración Natural a R

Lo que ya sabes en Excel:

```
=MAYUS(TRIM(C2))           // Limpiar texto  
=IF(D2<0,"NEG","OK")       // Condicionales  
=E2/F2                     // Operaciones  
=PROMEDIO(E2:E9)           // Funciones
```

Lo mismo en R:

```
str_to_title(str_trim(sector)) # Limpiar texto  
ifelse(ingresos < 0, "NEG", "OK") # Condicionales  
ingresos / empleados           # Operaciones  
mean(ingresos)                 # Funciones
```

¿Por qué Migrar a R?

Limitaciones de Excel - Manual (cada fila requiere fórmula) - No escala (millones de filas) - Difícil auditar - Difícil reproducir - Lento con datos grandes

Ventajas de R - Automático (aplica a toda columna) - Escala a millones de filas - Código transparente - Reproducible al 100 % - Muy rápido con datos grandes

El Ecosistema tidyverse

R utiliza el paquete **tidyverse** (incluye dplyr, stringr, tidyr) como herramienta principal de limpieza. La lógica es similar a Power Query: un **pipeline** donde cada paso transforma los datos y pasa el resultado al siguiente usando el operador `%>%`.

```
# El operador %>% (pipe) conecta pasos como Power Query
datos %>%
  paso_1() %>%      # Equivale a un "Paso aplicado"
  paso_2() %>%      # Se ejecuta sobre el resultado anterior
  paso_3()           # Resultado final
```

Lectura: “Toma datos, LUEGO aplica paso 1, LUEGO paso 2...”

Funciones de Texto (equivalentes a Power Query)

```
library(tidyverse)

datos %>% mutate(
  # Recortar espacios (= Text.Trim)
  pais = str_trim(pais),

  # Mayúsculas (= Text.Upper)
  pais = toupper(pais),

  # Minúsculas (= Text.Lower)
  sector = tolower(sector),

  # Título (= Text.Proper / Mayúscula cada palabra)
  sector = str_to_title(sector),

  # Reemplazar texto (= Replacer.ReplaceText)
  monto = str_remove_all(monto, "\\$"),
```

Funciones Numéricas y de Filtro

```
datos %>%  
  # Convertir texto a número (= TransformColumnTypes)  
  mutate(monto = as.numeric(monto)) %>%  
  
  # Valor absoluto (= Number.Abs)  
  mutate(monto = abs(monto)) %>%  
  
  # Redondear  
  mutate(tasa = round(tasa, 2)) %>%  
  
  # Filtrar filas (= Table.SelectRows)  
  filter(monto > 0, !is.na(fecha)) %>%  
  
  # Eliminar duplicados (= Table.Distinct)  
  distinct() %>%  
  
  # Eliminar duplicados por columna
```

Funciones para Datos Faltantes

```
datos %>% mutate(  
  # Reemplazar NA con valor fijo (= ReplaceValue null)  
  arancel = replace_na(arancel, 12.27),  
  empleados = replace_na(empleados, 268),  
  
  # Reemplazar NA con mediana global  
  volumen = ifelse(is.na(volumen),  
                    median(volumen, na.rm = TRUE),  
                    volumen),  
  
  # Reemplazar NA con mediana POR GRUPO  
  # (esto NO se puede hacer en Power Query fácilmente)  
  monto = ifelse(is.na(monto),  
                  median(monto, na.rm = TRUE),  
                  monto),  
  .by = sector # ← calcula mediana dentro de cada sector  
)
```

Ejemplo: Pipeline de Limpieza en R

Lo que hiciste en Excel (9 pasos) en R (5 líneas):

```
# Cargar datos
datos <- read.csv("datos_crudos.csv")

# PIPELINE COMPLETO DE LIMPIEZA
datos_limpios <- datos %>%
  # Limpiar texto
  mutate(sector = str_trim(sector) %>% str_to_title()) %>%
  # Convertir fechas
  mutate(fecha = as.Date(fecha, format="%Y-%m-%d")) %>%
  # Marcar negativos
  mutate(ingreso_negativo = ingresos < 0,
         ingresos = abs(ingresos)) %>%
  # Imputar faltantes
  mutate(empleados = ifelse(is.na(empleados),
                             median(empleados, na.rm=TRUE),
                             empleados)) %>%
```

PASO 1: Excel (entiendes CÓMO se hace)



PASO 2: R (entiendes POR QUÉ es mejor)



PASO 3: Migración (usas R para proyectos grandes)



PASO 4: Dominio (Excel para exploración, R para producción)

Checkpoint: Preguntas de Verificación

Responde internamente:

- 1 ¿Cuál es el propósito principal de la limpieza de datos?
- 2 ¿Por qué es importante documentar variables?
- 3 ¿Qué herramienta de Excel usaste para limpiar espacios?
- 4 ¿Qué ventaja tiene R sobre Excel para datos grandes?
- 5 ¿Cuándo usarías Excel y cuándo usarías R?

Sesión 2: Estadística Descriptiva

Ahora con datos limpios, aprenderemos a:

- Crear tablas de frecuencia
- Calcular medidas de tendencia central (media, mediana, moda)
- Calcular medidas de dispersión (desviación estándar, IQR)
- **Visualizar con gráficos** (histogramas, boxplots)
- Interpretar indicadores económicos

Preparación: Traer los datos limpios de esta sesión

Textos Esenciales

- Broman, K. W., & Woo, K. H. (2018). "Data organization in spreadsheets." *The American Statistician*, 72(1), 2-10.
- Batini, C., Cappiello, C., Francalanci, C., & Maurino, A. (2009). "Methodologies for data quality assessment and improvement." *ACM Computing Surveys*, 41(3), 1-52.
- Wickham, H., & Grolemund, G. (2017). *R for Data Science: Import, Tidy, Transform, Visualize, and Model Data*. O'Reilly Media.

- **Microsoft Excel Documentation:**
<https://support.microsoft.com/en-us/excel>
- **R Data Wrangling:** <https://r4ds.hadley.nz/>
- **tidyverse Guide:** <https://www.tidyverse.org/>