

Estadística Descriptiva e Inferencial Aplicada

Sesión 5: Regresión Lineal e Introducción a Series de Tiempo

Escuela Global

2026-09-18

Introducción

¿Dónde Estamos?

En la Sesión 4 aprendimos a **comparar grupos** (pruebas t) y **estimar promedios** (intervalos de confianza). Hoy damos el siguiente paso: **modelar relaciones** entre variables para explicar y predecir.

Dos bloques de la sesión:

BLOQUE 1: REGRESIÓN LINEAL

Datos: ENAHO 2025 - Módulo 500 (corte transversal)

Pregunta: ¿Cómo se relaciona el ingreso con la edad, educación y área de residencia?



BLOQUE 2: SERIES DE TIEMPO

Datos: series_peru.dta (PIB, impuestos, comercio 2000-2020)

Pregunta: ¿Cómo evolucionan las variables macro en el tiempo y qué podemos pronosticar?

Al término de esta sesión, el participante será capaz de:

1. Estimar e interpretar un modelo de regresión lineal simple y múltiple
2. Evaluar el ajuste del modelo (R^2 , significancia de coeficientes)
3. Diagnosticar los supuestos del modelo (residuos, normalidad, heterocedasticidad)
4. Declarar y graficar una serie de tiempo en Stata
5. Calcular y interpretar autocorrelación (ACF/PACF)
6. Descomponer una serie en tendencia, estacionalidad y ruido
7. Generar un pronóstico simple

Parte 1: Regresión Lineal Simple

¿Qué es la Regresión Lineal?

Definición

La regresión lineal modela la relación entre una variable dependiente Y y una o más variables independientes X , asumiendo una relación lineal:


$$Y = \beta_0 + \beta_1 X + \varepsilon$$

Componentes:

- ▶ β_0 : intercepto (valor de Y cuando $X = 0$)
- ▶ β_1 : pendiente (cambio en Y por cada unidad de X)
- ▶ ε : término de error (lo que el modelo no explica)

Ejemplo económico: ¿Cómo cambia el ingreso (Y) a medida que aumenta la edad (X)?

Visualización: La Línea de Mejor Ajuste



La regresión encuentra la línea que **minimiza la suma de los errores al cuadrado** (Mínimos Cuadrados Ordinarios, MCO).

La Idea

MCO elige $\hat{\beta}_0$ y $\hat{\beta}_1$ de forma que minimicen:

$$\sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \sum_{i=1}^n \varepsilon_i^2$$

Fórmulas de los estimadores:

$$\hat{\beta}_1 = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sum (X_i - \bar{X})^2} \quad \hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

Supuestos clave (Gauss-Markov):

1. Relación lineal en los parámetros
2. Errores con media cero
3. Homocedasticidad (varianza constante del error)
4. No autocorrelación de los errores
5. Errores normalmente distribuidos (para inferencia)

¿Qué Proporción de la Variación Explica el Modelo?

$$R^2 = 1 - \frac{\sum(Y_i - \hat{Y}_i)^2}{\sum(Y_i - \bar{Y})^2} = 1 - \frac{SCR}{SCT}$$

R^2	Interpretación
0.00 - 0.30	Ajuste débil
0.30 - 0.60	Ajuste moderado
0.60 - 0.90	Ajuste fuerte
> 0.90	Ajuste muy fuerte (revisar sobreajuste)

Cuidado: Un R^2 alto no implica causalidad, solo asociación lineal.

Regresión Simple en Stata

Código:

```
use "enaho01a-2025-500.dta", clear

** Regresión: ingreso sobre edad
regress i524a1 p208a

** Interpretar:
** Coeficiente de p208a = cambio en ingreso por cada
** año adicional de edad
** Constante (_cons) = ingreso esperado a edad = 0
** R-squared = proporción de varianza explicada
```

Salida típica:

Source	SS	df	MS	
Model	1.234e+09	1	1.234e+09	
Residual	5.678e+10	798	71152893	
Total	5.801e+10	799	72602345	R-squared = 0.0213

	Coef.	Std.Err.	t	P> t
i524a1				
p208a	18.45	3.21	5.75	0.000

Modelo Estimado

$$\widehat{\text{ingreso}} = 1050.30 + 18.45 \times \text{edad}$$

Lectura del coeficiente de edad (18.45):

"Por cada año adicional de edad, el ingreso esperado aumenta en S/ 18.45, manteniendo todo lo demás constante."

Lectura de la constante (1050.30):

*"Una persona de 0 años tendría un ingreso esperado de S/ 1050.30"
— interpretación poco útil aquí; la constante rara vez tiene sentido económico directo cuando $X = 0$ no es un valor observado en los datos.*

Significancia ($p < 0.001$): El efecto de la edad sobre el ingreso es estadísticamente significativo.

Ejercicio 1: Regresión Simple (70 % Stata)

Situación

La oficina de estudios económicos quiere cuantificar la relación entre edad e ingreso laboral usando la ENAHO 2025.

Archivo: enaho01a-2025-500.dta

Pasos en Stata:

```
use "enaho01a-2025-500.dta", clear  
regress i524a1 p208a
```

Preguntas:

1. ¿Cuál es el coeficiente de la edad? Interpretalo.
2. ¿Es significativo al 5 %?
3. ¿Cuál es el R^2 ? ¿El modelo explica mucho o poco?
4. Predice el ingreso esperado para una persona de 40 años.

Parte 2: Regresión Lineal Múltiple

Modelo Múltiple

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_k X_k + \varepsilon$$

Ventaja: Controla por variables que podrían confundir la relación de interés (*ceteris paribus*).

Ejemplo: El ingreso puede depender de edad, área de residencia y sector económico simultáneamente.

$$\text{ingreso} = \beta_0 + \beta_1 \text{edad} + \beta_2 \text{area_urb} + \beta_3 \text{educ} + \varepsilon$$

El Problema

No se puede meter directamente una variable de texto ("Urbano"/"Rural") en una regresión. Se convierte en una **variable dummy** (0/1).

En Stata, con i. (factor variable):

```
** Stata crea la dummy automáticamente  
regress i524a1 p208a i.area_res
```

```
** Equivalente manual:  
gen urbano = (area_res == 1)  
regress i524a1 p208a urbano
```

Interpretación de la dummy: el coeficiente mide la diferencia promedio respecto a la categoría base (omitida).

Código:

```
use "enaho01a-2025-500.dta", clear

gen area_res = .
replace area_res = 1 if inlist(estrato,1,2,3,4,5)
replace area_res = 2 if inlist(estrato,6,7,8)
label define area_lbl 1 "Urbano" 2 "Rural"
label values area_res area_lbl

** Regresión múltiple con variable categórica
regress i524a1 p208a i.area_res

** Con interacción edad x área
regress i524a1 c.p208a##i.area_res

** Ver coeficientes estandarizados (beta)
regress i524a1 p208a i.area_res, beta
```

Modelo Estimado

$$\widehat{\text{ingreso}} = 850.2 + 15.3 \text{ edad} + 620.5 \text{ Urbano}$$

Lectura:

- ▶ **Edad (15.3):** Por cada año adicional, el ingreso sube S/ 15.3, **controlando por área de residencia.**
- ▶ **Urbano (620.5):** Los hogares urbanos ganan en promedio S/ 620.5 más que los rurales, **controlando por edad.**

Nota clave: El coeficiente de edad cambió de 18.45 (modelo simple) a 15.3 (modelo múltiple) porque parte del efecto de la edad estaba “capturando” también el efecto del área de residencia.

El Problema

Cuando dos o más variables independientes están altamente correlacionadas entre sí, los coeficientes se vuelven inestables y difíciles de interpretar.

Detección en Stata:

```
regress i524a1 p208a i.area_res
```

```
** Factor de Inflación de Varianza (VIF)  
estat vif
```

```
** Regla práctica:
```

```
** VIF < 5 → sin problema
```

```
** VIF 5-10 → multicolinealidad moderada
```

```
** VIF > 10 → multicolinealidad severa, revisar modelo
```

Situación

El área de estudios quiere un modelo más completo que controle por área de residencia además de la edad.

Pasos en Stata:

```
regress i524a1 p208a i.area_res  
estat vif
```

Preguntas:

1. ¿Cambió el coeficiente de edad respecto al modelo simple?
2. ¿Cuál es la diferencia de ingreso entre Urbano y Rural?
3. ¿Hay problemas de multicolinealidad (VIF)?
4. ¿Aumentó el R^2 respecto al modelo simple?

Parte 3: Diagnóstico del Modelo

¿Por Qué Diagnosticar?

Si los supuestos de MCO no se cumplen, los coeficientes pueden ser sesgados o los errores estándar incorrectos, invalidando la inferencia.

Gráfico de residuos vs valores ajustados:

```
regress i524a1 p208a
rvfplot, yline(0) ///
    title("Residuos vs Valores Ajustados") ///
    msize(tiny) mcolor(navy%40)
```

Qué buscar: Los puntos deben distribuirse aleatoriamente alrededor de cero, sin patrón (embudo, curva). Un patrón sugiere heterocedasticidad o relación no lineal.

Código:


```
regress i524a1 p208a
predict residuos, resid

** Histograma con curva normal
hist residuos, normal ///
    title("Distribución de los Residuos")

** Gráfico Q-Q
qnorm residuos, title("Q-Q Plot de Residuos")

** Test formal
swilk residuos
```

Q-Q Plot de Residuos: Resultado



Si los puntos siguen la línea recta, los residuos son aproximadamente normales.

El Problema

Ocurre cuando la varianza del error **no es constante** a través de los valores de X. Es común en datos de ingresos (mayor dispersión en ingresos altos).

Detección formal en Stata:

```
regress i524a1 p208a i.area_res

** Test de Breusch-Pagan
estat hettest

** H0: Varianza constante (homocedasticidad)
** Si  $p < 0.05$  → Rechazar H0 → Hay heterocedasticidad
```

Solución: Errores estándar robustos:

```
regress i524a1 p208a i.area_res, robust
```

Ejercicio 3: Diagnóstico (70 % Stata)

Situación

Antes de reportar el modelo múltiple, se debe verificar que cumple los supuestos básicos.

Pasos en Stata:

```
regress i524a1 p208a i.area_res  
predict residuos, resid  
predict ajustados, xb  
  
rvfplot, yline(0)  
hist residuos, normal  
estat hettest  
estat vif
```

Preguntas:

1. ¿Se observa patrón en el gráfico de residuos?
2. ¿Los residuos parecen normales?
3. ¿El test de Breusch-Pagan detecta heterocedasticidad?
4. Si hay heterocedasticidad, vuelve a estimar con robust. ¿Cambian mucho los errores estándar?

Parte 4: Series de Tiempo — Fundamentos

¿Qué es una Serie de Tiempo?

Definición

Una serie de tiempo es una secuencia de observaciones de una variable, ordenadas cronológicamente y típicamente espaciadas en intervalos regulares (diario, mensual, trimestral, anual).

Dataset de esta sección: `series_peru.dta`

Variable	Descripción
<code>date</code>	Trimestre (formato "2000:01" a "2020:04")
<code>taxes</code>	Recaudación tributaria
<code>gdp</code>	Producto Bruto Interno (PIB)
<code>exports</code>	Exportaciones
<code>imports</code>	Importaciones

84 observaciones trimestrales: 2000Q1 - 2020Q4 (21 años).

Declarar la Serie de Tiempo en Stata

El Comando `tsset`

Antes de cualquier análisis de series de tiempo, Stata necesita saber cuál es la variable temporal y su periodicidad.

Código:

```
use "series_peru.dta", clear

** Convertir la variable date (texto) a formato trimestral
gen fecha = quarterly(date, "YQ")
format fecha%tq

** Declarar la serie de tiempo
tsset fecha

** Verificar
tsset
describe
```

Salida esperada:


```
Time variable: fecha, 2000q1 to 2020q4
Delta: 1 quarter
```

Código:

```
tsset fecha

** Gráfico simple de una serie
tsline gdp, ///
    title("PIB trimestral del Perú") ///
    ytitle("PIB (millones S/)") ///
    xtitle("") ///
    lcolor(navy) lwidth(medthick)
```

PIB en el Tiempo: Resultado




Observación: Tendencia creciente con estacionalidad marcada y una caída abrupta en 2020 (pandemia COVID-19).

Código:

```
tsline exports imports, ///  
  title("Comercio Exterior del Perú") ///  
  ytitle("Millones S/") ///  
  legend(order(1 "Exportaciones" 2 "Importaciones")) ///  
  lcolor(navy cranberry)
```

Comercio Exterior: Resultado



Ejercicio 4: Explorar la Serie (70 % Stata)

Situación

El área de investigación económica necesita un primer diagnóstico visual de las series macroeconómicas antes de modelarlas.

Pasos en Stata:

```
use "series_peru.dta", clear
gen fecha = quarterly(date, "YQ")
format fecha%tq
tsset fecha

tsline gdp
tsline taxes
tsline exports imports
```

Preguntas:

1. ¿El PIB muestra tendencia creciente o decreciente?
2. ¿Se observa estacionalidad (patrón que se repite cada 4 trimestres)?
3. ¿Qué ocurre en 2020? ¿A qué evento corresponde?
4. ¿Exportaciones e importaciones se mueven juntas?

Parte 5: Autocorrelación

¿Qué es la Autocorrelación?

Definición

La autocorrelación mide qué tan relacionado está el valor de una serie en el tiempo t con sus propios valores en tiempos pasados ($t - 1, t - 2, \dots$).

$$\rho_k = \text{Corr}(Y_t, Y_{t-k})$$

¿Por qué importa?

- ▶ Series económicas casi siempre están autocorrelacionadas (el PIB de hoy se parece al de ayer)
- ▶ Es la base para elegir modelos de pronóstico (AR, MA, ARIMA)
- ▶ Ignorarla en una regresión viola el supuesto de independencia de errores


Función de Autocorrelación (ACF)

Código:

```
tsset fecha

** Correlograma (ACF)
corrgram gdp, lags(20)

** Gráfico de ACF
ac gdp, lags(20) ///
    title("Función de Autocorrelación (ACF)")
```



Interpretación: Barras que superan la banda azul (intervalo de confianza) indican autocorrelación significativa en ese rezago. El decaimiento lento sugiere una tendencia no estacionaria.

Función de Autocorrelación Parcial (PACF)


Diferencia con la ACF

La PACF mide la correlación entre Y_t y Y_{t-k} **eliminando el efecto de los rezagos intermedios** ($t-1, \dots, t-k+1$).

Código:

```
** Gráfico de PACF  
pac gdp, lags(20) ///  
    title("Función de Autocorrelación Parcial (PACF)")
```

Uso práctico: ACF y PACF juntas ayudan a identificar el orden de un modelo ARIMA(p,d,q).



¿Por Qué Importa la Estacionariedad?

Una serie es **estacionaria** si su media, varianza y autocorrelación no cambian en el tiempo. La mayoría de modelos de series de tiempo requieren estacionariedad.

Código:

```
** Test de Dickey-Fuller Aumentado
dfuller gdp, lags(4)

** H0: La serie tiene raíz unitaria (NO es estacionaria)
** Si  $p > 0.05 \rightarrow$  No se rechaza H0  $\rightarrow$  Serie NO estacionaria

** Si no es estacionaria, diferenciar:
gen d_gdp = D.gdp
dfuller d_gdp, lags(4)
```

Ejercicio 5: Autocorrelación (70 % Stata)

Situación

Antes de construir un modelo de pronóstico, se debe caracterizar la dependencia temporal del PIB.

Pasos en Stata:

```
tsset fecha  
corrgram gdp, lags(12)  
ac gdp, lags(12)  
pac gdp, lags(12)  
dfuller gdp, lags(4)
```

Preguntas:

1. ¿La ACF decae lentamente o rápidamente?
2. ¿Cuántos rezagos son significativos en la PACF?
3. Según Dickey-Fuller, ¿la serie es estacionaria?
4. Si no lo es, aplica primera diferencia y repite el test.

Parte 6: Descomposición y Pronóstico

Componentes de una Serie de Tiempo

$$Y_t = T_t + S_t + R_t$$

- ▶ T_t : Tendencia (movimiento de largo plazo)
- ▶ S_t : Estacionalidad (patrón que se repite cada período fijo)
- ▶ R_t : Residuo (componente aleatorio)


Código:

```
tsset fecha

** Instalar si es necesario: ssc install stl
** Descomposición (requiere el paquete stl o tsdecomp)
tsline gdp, name(original)

** Alternativa nativa: promedio móvil para ver tendencia
tssmooth ma gdp_tendencia = gdp, window(2 1 1)
tsline gdp gdp_tendencia
```

Descomposición Estacional: Resultado



Lectura: La tendencia muestra crecimiento sostenido (con la caída de 2020). El componente estacional se repite cada 4 trimestres. El residuo captura choques no explicados.

ARIMA(p , d , q)

- ▶ p : orden autorregresivo (AR) — cuántos rezagos de Y
- ▶ d : orden de diferenciación — cuántas veces diferenciar para lograr estacionariedad
- ▶ q : orden de media móvil (MA) — cuántos rezagos del error

Código:

```
tsset fecha

** Estimar un modelo ARIMA(1,1,1)
arima gdp, arima(1,1,1)

** Ver los coeficientes AR y MA
** Verificar significancia de cada término
```

Código:

```
tsset fecha


** Estimar el modelo
arima gdp, arima(1,1,1)

** Extender el período muestral para pronosticar
tsappend, add(8)

** Generar el pronóstico con intervalo de confianza
predict pron_gdp, y dynamic(tq(2021q1))
predict se_gdp, stdp

** Graficar observado + pronóstico
tsline gdp pron_gdp, ///
    title("PIB Observado y Pronosticado") ///
    legend(order(1 "Observado" 2 "Pronóstico"))
```

Pronóstico del PIB: Resultado



La zona sombreada representa el intervalo de confianza del pronóstico: la incertidumbre crece cuanto más lejos se pronostica.

Ejercicio 6: Pronóstico (70 % Stata)

Situación

La gerencia de planeamiento necesita una proyección del PIB para los próximos 8 trimestres (2 años).

Pasos en Stata:

```
tsset fecha  
dfuller gdp, lags(4)  
arima gdp, arima(1,1,1)  
tsappend, add(8)  
predict pron_gdp, y dynamic(tq(2021q1))  
tsline gdp pron_gdp
```

Preguntas:

1. ¿El modelo ARIMA(1,1,1) es adecuado según los residuos?
2. ¿Cuál es el PIB pronosticado para 2021Q1?
3. ¿El pronóstico captura la recuperación post-pandemia?
4. Prueba con ARIMA(2,1,1). ¿Mejora el ajuste (AIC/BIC)?

Cierre

Tarea	Comando Stata
Regresión simple	<code>regress y x</code>
Regresión múltiple	<code>regress y x1 x2 i.categorica</code>
Ver VIF	<code>estat vif</code>
Residuos vs ajustados	<code>rvfplot</code>
Heterocedasticidad	<code>estat hettest</code>
Errores robustos	<code>regress y x, robust</code>
Predecir valores	<code>predict yhat, xb</code>
Predecir residuos	<code>predict resid, resid</code>

Tarea	Comando Stata
Declarar serie	<code>tsset variable_tiempo</code>
Graficar serie	<code>tsline variable</code>
Autocorrelación	<code>ac variable, lags()</code>
Autocorr. parcial	<code>pac variable, lags()</code>
Correlograma	<code>corrgram variable</code>
Test de raíz unitaria	<code>dfuller variable</code>
Diferenciar	<code>gen d_var = D.variable</code>
Modelo ARIMA	<code>arima variable, arima(p,d,q)</code>
Pronosticar	<code>predict, dynamic()</code>

Regresión Lineal (ENAH 2025):

- ▶ Estimar e interpretar modelos simples y múltiples
- ▶ Evaluar ajuste (R^2) y significancia
- ▶ Diagnosticar residuos, normalidad y heterocedasticidad

Series de Tiempo (series_peru.dta):

- ▶ Declarar y graficar series temporales
- ▶ Calcular e interpretar ACF y PACF
- ▶ Evaluar estacionariedad con Dickey-Fuller
- ▶ Descomponer en tendencia y estacionalidad
- ▶ Generar un pronóstico con ARIMA

Sesión 6: Modelos Avanzados y Cierre del Curso

- ▶ Modelos de elección discreta (logit/probit)
- ▶ Regresión con datos de panel
- ▶ Buenas prácticas de reporte de resultados
- ▶ Proyecto integrador final

Preparación: Traer los modelos y pronósticos de esta sesión.

Textos Esenciales

- ▶ Wooldridge, J. (2015). *Introductory Econometrics: A Modern Approach*. 6th ed. Cengage.
- ▶ Hamilton, J. (1994). *Time Series Analysis*. Princeton University Press.
- ▶ Stock, J. & Watson, M. (2015). *Introduction to Econometrics*. 3rd ed. Pearson.
- ▶ Palomino, J. (2024). *Curso Stata PUCP*.
<https://github.com/juanpalominoh/Curso-Stata-PUCP>
- ▶ StataCorp. (2023). *Time-Series Reference Manual*.
<https://www.stata.com/manuals/ts.pdf>

Sesión 5: Regresión Lineal e Introducción a Series de Tiempo Escuela Global - Estadística Aplicada Datos: ENAHO 2025 (Módulo 500) y series_peru.dta